



Función Drop-Wave

Optimización con algoritmos genéticos

Alumno: Enrique Lisandro Flores Brito
Profesor: Jorge Hermosillo Valadez
Fecha de entrega: 26 de mayo de 2026

Índice de Contenidos

1. Descripción del proyecto	1
1.1. Contexto	1
1.1.1. Visualización	1
1.2. Problema	1
1.2.1. Espacio de búsqueda y óptimo global	1
1.2.2. Naturaleza del desafío	2
2. Planteamiento del problema	3
2.1. Definición de un estado del problema	3
2.2. Representación de un estado para el algoritmo de optimización	3
3. Metodología	4
Referencias	5

1. Descripción del proyecto

El presente trabajo aborda la optimización de la función Drop-Wave mediante la implementación de un Algoritmo Genético de codificación real¹.

1.1. Contexto

La función Drop-Wave no surge como el modelado de un fenómeno físico real en la naturaleza, sino que pertenece a la familia de las funciones de prueba sintéticas (benchmark functions) en el campo de las matemáticas aplicadas y las ciencias de la computación.

Fue diseñada y popularizada en la literatura de optimización como un entorno de prueba "hostil" para evaluar el rendimiento, la velocidad de convergencia y la robustez de los algoritmos de optimización global. Su origen está ligado a la necesidad de crear paisajes matemáticos que imiten la complejidad extrema de los problemas de la vida real, sirviendo como un estándar métrico. De hecho, autores como Molga y Smutnicki (2005) la catalogan como una de las funciones de referencia obligatorias para probar estrategias evolutivas.

1.1.1. Visualización

El nombre "Drop-Wave" proviene de su representación gráfica en tres dimensiones. Cuando se plotea, la superficie de la función se asemeja visualmente al impacto de una gota cayendo sobre una superficie de agua estancada, generando un punto central profundo rodeado de ondas circulares (anillos concéntricos) que se van disipando hacia los bordes.

La función se define típicamente en dos dimensiones mediante la siguiente ecuación:

$$f(x) = -\frac{1 + \cos\left(12\sqrt{x_1^2 + x_2^2}\right)}{0.5(x_1^2 + x_2^2) + 2}$$

1.2. Problema


El problema central de este proyecto consiste en la optimización de la función Drop-Wave, la cual está catalogada como una función de prueba (benchmark) de tipo multimodal. El objetivo principal es encontrar el punto donde esta función alcanza su valor mínimo posible dentro de un espacio de búsqueda determinado.

1.2.1. Espacio de búsqueda y óptimo global

Para delimitar el problema de optimización, se establecen las siguientes condiciones de frontera y metas teóricas:

- **Espacio de Búsqueda:** El dominio para la evaluación de las soluciones está definido estrictamente en el intervalo continuo $x_i \in [-5.12, 5.12]$.

¹ El código fuente completo de la implementación en Python, así como las visualizaciones interactivas, se encuentran disponibles en el repositorio: <https://github.com/enriqfl/Optimizacion-funcion-Drop-Wave>



- **Mínimo Global:** El valor óptimo teórico que el algoritmo debe buscar alcanzar se localiza en el origen de las coordenadas, donde $f(0, 0) = -1$.

1.2.2. Naturaleza del desafío

La dificultad principal que introduce la función Drop-Wave es la presencia de múltiples mínimos locales distribuidos en forma de ondas concéntricas alrededor del centro. Esta característica topológica castiga fuertemente la falta de diversidad durante la búsqueda.

Si el método de optimización no posee el impulso suficiente para "saltar" las crestas de estas ondas (lo cual en los algoritmos genéticos se logra mediante el operador de mutación), la población tiende a estancarse y converger prematuramente en los anillos exteriores, perdiendo la capacidad de encontrar el pozo central en el origen.

2. Planteamiento del problema

2.1. Definición de un estado del problema

En el contexto de la optimización de la función Drop-Wave, un estado E representa un punto de evaluación específico sobre la superficie multidimensional de la función; es decir, una posible solución al problema.

Matemáticamente, debido a la naturaleza de la función, un estado cualquiera se describe de manera precisa como un vector o 2-tupla de números reales:

$$E := (x_1, x_2) \text{ con } x_i \in \mathbb{R}$$

Cada componente x_i de la tupla representa una coordenada espacial en el plano base sobre el cual se proyecta la superficie de la función. El problema parte de un estado inicial (o múltiples estados iniciales) generados aleatoriamente, y el objetivo es encontrar un estado final $E_f = (0, 0)$ que, al ser evaluado, resulte en el mínimo global teórico de -1 .

2.2. Representación de un estado para el algoritmo de optimización

Dado que el método de solución se basa en algoritmos genéticos, cada estado E funge como un individuo (o cromosoma) dentro de una población. Para asegurar la compatibilidad con los operadores evolutivos en un dominio continuo, se adopta una representación mediante codificación real.

El espacio de búsqueda está conformado por todos los números reales comprendidos en el dominio delimitado por la función, es decir:

$$[-5.12, 5.12] \times [-5.12, 5.12]$$

La representación de x_1 y x_2 como números de punto flotante es fundamental para explorar activamente este espacio continuo, ya que permite la aplicación directa de las siguientes operaciones genéticas:

- **Operación de cruce:** La representación vectorial real permite realizar una recombinación aritmética, donde los genes de los padres se promedian o interpolan matemáticamente para producir descendientes viables dentro de los límites del espacio de búsqueda.
- **Operación de mutación:** Al ser números reales, la mutación se implementa mediante la inyección de ruido Gaussiano a los valores de x_1 o x_2 . Esta alteración matemática es vital para que el individuo resultante logre "saltar" las múltiples crestas que caracterizan a la función Drop-Wave, proveyendo la diversidad necesaria para escapar de los mínimos locales concéntricos.

3. Metodología

Para abordar la optimización de la función Drop-Wave, se diseñó e implementó un Algoritmo Genético (AG) de codificación real. El proceso evolutivo opera sobre una población constante de 100 individuos a lo largo de 40 generaciones. La estrategia para la transición de estados y la selección de nuevos individuos se divide en los siguientes mecanismos iterativos:

- **Inicialización y Evaluación:** La población inicial se distribuye aleatoriamente en el espacio de búsqueda continuo mediante una distribución uniforme iterada en el intervalo $[-5.12, 5.12]$. La calidad de cada individuo se cuantifica mediante una función de aptitud o *fitness*. Dado que el objetivo es minimizar $f(x)$, la función de aptitud está diseñada para maximizar su negativo algebraico, es decir, $\Phi(x) = -f(x)$.
- **Elitismo:** Para asegurar una convergencia monótona y evitar la pérdida accidental de soluciones óptimas, se aplica un criterio de elitismo estricto. El individuo con la mayor aptitud de la generación actual pasa directamente y sin modificaciones a la siguiente generación.
- **Selección de progenitores:** La extracción de padres de la población se realiza mediante una selección por torneo con un tamaño de $k = 3$. Se eligen aleatoriamente tres candidatos y el que posea el valor más alto en la función de aptitud gana el derecho a reproducirse, garantizando una presión selectiva constante.
- **Cruza (Recombinación):** Se aplica un cruce aritmético para explotar las regiones prometedoras del espacio. Por cada par de padres seleccionados, se genera un peso aleatorio $\alpha \in [0, 1]$. Los dos hijos resultantes son combinaciones lineales de los progenitores, asegurando que su ubicación permanezca dentro del dominio válido.

$$\vec{h}_1 = \alpha \vec{p}_1 + (1 - \alpha) \vec{p}_2$$

$$\vec{h}_2 = (1 - \alpha) \vec{p}_1 + \alpha \vec{p}_2$$

- **Mutación:** Para preservar la diversidad poblacional y otorgar a los individuos la capacidad de "saltar" los múltiples mínimos locales (crestas) de la función Drop-Wave, se emplea una mutación gaussiana. Cada gen (coordenada) tiene un 15 % de probabilidad de ser mutado. Si la mutación ocurre, se le añade un ruido aleatorio extraído de una distribución normal centrada en 0 con una desviación estándar $\sigma = 0.5$. Posteriormente, se aplica un mecanismo de restricción (*clipping*) para forzar que la nueva coordenada no exceda los límites de ± 5.12 .

Referencias

- [1] Molga, M. y Smutnicki, C., “Test functions for optimization needs”, Test functions for optimization needs, vol. 101, no. 48, p. 32, 2005.
- [2] Surjanovic, S. y Bingham, D., “Virtual library of simulation experiments: Drop-wave function”. Simon Fraser University, 2013, <https://www.sfu.ca/~ssurjano/drop.html>.